


AutoEncoder

01


AutoEncoder



차원 축소란?

고차원의 데이터를 저차원으로 줄이는 알고리즘

엄청나게 많은 변수를 가지고 있는 고차원의 데이터에서는 차원의 저주가 발생할 가능성이 높아짐



딥러닝으로 차원축소를 하고 싶다면?

비지도학습

$X \rightarrow X'$

표현 학습(Representation Learning)

딥러닝에서 **고차원 데이터의 "표현(Representation)"**을 배운다는 것은 중요한 주제입니다.

- 표현 학습(Representation Learning)은 원본 데이터(raw data)에서 중요한 특징(feature)을 자동으로 학습하여, 모델이 더 효과적으로 학습할 수 있도록 하는 기법입니다.
- 사람이 직접 특징을 설계하는 수동 특징 엔지니어링(Feature Engineering)과 대비됩니다.

표현학습의 주요 기법

- 신경망의 은닉층
예) CNN의 초반 층은 가장자리를 학습하고, 후반 층은 객체의 형태를 학습
- 오토인코더
입력 데이터를 압축하여 의미 있는 표현(latent representation)을 학습

표현 학습(Representation Learning)

- 설명1.

- 안경을 쓰고 웃고 있다
- 입이 살짝 돌출형이다.
- 마르고 탄탄한 체격이다
- ...



- 설명2.

- 1x1 픽셀 RGB 값
- 1x2 픽셀 RGB 값
- ...
- 540x720 픽셀 RGB값

표현 학습(Representation Learning)

- 설명1.
 - 안경을 쓰고 웃고 있다
 - 입이 살짝 돌출형이다.
 - 마르고 탄탄한 체격이다
 - ...
- 이런 설명이 10개 정도 있으면 상대방은 그림으로 그려낼 수 있을 겁니다.
이 이미지는 완벽하지는 않겠지만 유재석님을 티비에서 보고 구별할 수 있을 정도로 실제와 유사할 것입니다.

이것이 표현학습(Representation Learning)에 깔려 있는
핵심 아이디어입니다.



표현 학습(Representation Learning)

즉, 표현학습이란


고차원 표본 공간을 직접 모델링 하는 방식이 아니라 대신

저차원의 잠재공간(latent space)을 사용해 훈련 세트의 각 샘플을 표현하고 이를 원본 공간의 포인트에 매핑합니다.

- 학습 데이터 -> 잠재공간 생성 -> 잠재공간의 각 포인트는 어떤 고차원 이미지에 대한 표현

표현 학습(Representation Learning)

원기둥 데이터셋



이 데이터셋을 2가지 특성으로 표현하려면?

이 데이터셋을 저차원의 잠재공간으로 표현하려면?

잠재공간




Figure 1-8. The 2D latent space of biscuit tins and the function f that maps a point in the latent space back to the original image domain

표현 학습(Representation Learning)

훈련 세트의 이미지가 고차원 픽셀 공간으로 주워지더라도
각 원통 이미지를 2차원의 잠재 공간의 한 포인트로 변환할 수 있습니다.

또한 적절한 매핑함수 f 를 잠재 공간의 새로운 포인트에 적용하여
훈련 세트에 없는 새로운 원기둥 이미지를 생성할 수도 있습니다.

의미 있는 잠재공간에서 표현 벡터를 조작하여 이미지의 고수준 속성에 영향을 미치는 연산을 수행할 수 있습니다.

원기둥의 높이를 살짝 키우고 싶을 때,
개별 픽셀을 하나하나 다 조정하는 것이 아니라
잠재공간의 높이 차원에 1을 더하고 매핑함수를 적용해 이미지를 얻습니다.

표현 학습(Representation Learning)

원본 데이터 셋을 간단한 잠재공간으로 설명할 수 있음을 기계가 학습하는 것은 쉽지 않습니다.

"높이"와 "너비"가 이 데이터셋을 가장 잘 설명하는 두 개의 잠재공간 차원임을 알아야 합니다

이 공간의 한 포인트를 회색 원통에 매핑하는 매핑함수 f 를 학습해야 합니다.

Auto Encoder

- AutoEncoder(자동 인코더)는 입력 데이터를 저차원 표현(latent space)으로 압축하고, 다시 원본과 유사한 데이터를 복원하는 신경망 모델
- 라벨이 없는 학습 데이터에서 더 낮은 차원의 특징 표현(feature representation)을 학습하는 비지도 학습 접근법(unsupervised approach)
- 주로 차원 축소, 특징 학습, 이상 탐지 등에 활용



Autoencoder




Encoder-Decoder 구조

Encoder:

- 데이터를 압축된 형태로 변환하는 역할을 수행
- 고차원 데이터를 저차원으로 변환하여 핵심 특징을 추출
- 예: 이미지를 입력받아, 해당 이미지의 중요한 특징만 포함된 벡터로 변환

Decoder:

- 압축된 표현을 다시 원래 데이터로 복원하거나, 새로운 형태로 변환
- Encoder의 결과물(잠재 표현)을 기반으로 데이터를 재구성
- 예: Latent Vector를 받아 이미지를 복원.



AutoEncoder

- 2D의 무한한 공간에 온갖 종류의 옷들을 나타낸다고 해봅시다.

인코딩


: 각각의 옷을 특정 위치로 이동시키는 과정

디코딩:


위치(벡터)로부터 옷을 생성하는 과정

임베딩 :

고차원 데이터(옷 이미지)를
저차원의 벡터 공간(점)으로 표현하는 과정




AutoEncoder의 구조



AutoEncoder의 구조

- 인코더 : 이미지 같은 고차원 입력 데이터를 저차원 임베딩 벡터로 압축합니다.
- 디코더 : 임베딩 벡터를 원본 도메인으로 압축 해제합니다.



Encoder (인코더)


- 입력 데이터를 저차원(latent space) 표현으로 변환하는 역할
- 일반적으로 다층 퍼셉트론(MLP) 또는 CNN, RNN을 사용하여 구성
- 입력 데이터보다 작은 차원의 숨겨진 표현(잠재 변수, latent representation)을 학습

Decoder (디코더)

- 인코더가 만든 저차원 표현을 원래 데이터 차원으로 복원하는 역할
- 인코더의 반대 구조를 가짐
- 복원된 출력이 원본 입력과 최대한 유사하도록 학습

AutoEncoder

관측
(observation)




잠재
(Latent)




- 원래 :선형 변환(Linear)과 비선형 활성화 함수(Sigmoid) 사용.
- 이후 :딥러닝 발전과 함께 Deep, Fully-Connected Layers (깊은 완전 연결층) 적용.
- 최근에는 ReLU CNN으로 발전하여 이미지를 다루는 데 적합한 구조 채택.


AutoEncoder



AutoEncoder



AutoEncoder



AutoEncoder의 학습과정


AutoEncoder는 입력과 출력을 동일하게 두고 학습하는 특징이 있습니다.

1. 입력 데이터(x)를 인코더에 전달하여 잠재 변수(z)를 생성
2. 디코더를 통해 z 에서 원본과 유사한 데이터(x')를 복원
3. 입력 x 와 출력 x' 간의 차이를 최소화하도록 손실 함수(예: MSE)를 사용하여 모델 최적화

$$L = ||x - x'||^2$$

라벨을 사용하지 않습니다!

AutoEncoder



AutoEncoder 구조와 활용

Image Denoising






Image Generation



AutoEncoder 구조와 활용

Image Denoising



감사합니다 😊